

多特征预示人工智能预测算法说明文档

目录

1 多特征预示人工智能时频估计方法研究	2
1.1 线性时频分析方法	2
1.2 二次时频分析方法	7
1.3 自适应性非参数时频分析方法	16
2 多特征预示人工智能预测经典算法研究	24
2.1 决策树(DT).....	25
2.2 随机森林 (RF).....	28
2.3 支持向量机 (SVM).....	31
2.4 极端树 (ET).....	35
3 多特征预示人工智能预测多任务回归算法研究	38
3.1 GroupLasso: 基于 L1/L2 混合范数正则化的多任务学习模型.....	38
3.2 Multitask Wasserstein: 基于 Wasserstein 距离正则化的稀疏多任务回归模型 ..	41
3.3 Reweighted Multitask Wasserstein: 基于 Wasserstein 距离正则化和 L0.5 稀疏约束的多任务回归模型	43
4 多特征预示人工智能预测深度学习算法	46
4.1MMoE: 多门控混合专家模型.....	46
4.2 MLP: 多层感知机模型	49
5 多特征预示人工智能预测性能评估方法	53
5.1 评估体系设计原则	53
5.2 核心评估指标与计算方法	54
5.2.2 泛化能力指标 (衡量模型稳定性与适应性)	55
5.2.3 计算效率指标 (适配大数据与实时场景)	56
5.3 特征有效性与模型可解释性评估	56

1 多特征预示人工智能时频估计方法研究

1.1 线性时频分析方法

线性时频分析方法通过线性变换将信号映射到时间 - 频率域，核心特点是时频分布满足线性叠加原理，即多分量信号的时频分布等于各分量时频分布的直接叠加，无交叉项干扰，但受 Heisenberg 不确定原理限制，时频分辨率存在固有 trade-off。以下重点介绍短时傅里叶变换（STFT）、连续小波变换（CWT）与 S 变换（ST）三种典型方法。

1.1.1 短时傅里叶变换（STFT）

STFT 是最早的线性时频分析方法之一，由 Gabor 系统提出，核心思想是通过固定窗函数将非平稳信号分割为短时平稳“小片段”，再对每个片段做傅里叶变换，最终拼接形成时频分布。

- 数学表达式

对于连续时间信号 $s(t)$ ，其 STFT 的积分形式为：

$$S_F(\tau, f) = \int_{-\infty}^{+\infty} s(t)w(t - \tau)e^{-j2\pi ft}dt$$

其中， $w(t)$ 为窗函数（如矩形窗、汉宁窗、汉明窗）， τ 为时间平移参数（确定分析时间位置）， f 为频率参数， $S_F(\tau, f)$ 代表信号在 $t = \tau$ 、 f 处的时频幅度。

也可表示为内积形式，更清晰体现局部化与频率提取过程：

$$S_F(\tau, f) = \langle s(t) * w(-t), e^{j2\pi ft} \rangle_\tau$$

式中，*为卷积运算， $\langle \cdot, \cdot \rangle_\tau$ 为时间平移 τ 处的内积，反映窗函数与信号卷积实现局部化后，再与正弦函数内积提取频率信息的逻辑。

- 窗函数特性与影响

窗函数的选择直接决定 STFT 的时频分析效果，不同窗函数的时域 - 频域特性差异显著：

- 矩形窗：时域为矩形，频域主瓣窄（频率分辨率高），但旁瓣幅度大（易产生频谱泄漏）；
- 汉宁窗（Hanning 窗）：时域呈余弦平方形，频域主瓣宽于矩形窗（频率分辨率降低），但旁瓣幅度大幅减小（频谱泄漏抑制效果好）；
- 汉明窗（Hamming 窗）：与汉宁窗时域形态接近，频域旁瓣抑制效果略优，主瓣宽度相近。

需注意的是，STFT 的窗函数在分析过程中固定不变，受 Heisenberg 不确定原理严格限制：窗宽增大时，时间分辨率降低、频率分辨率提高；窗宽减小时则相反，无法同时实现时间与频率的高分辨率，对快速时变信号（如冲击、调频信号）分析效果有限。

1.1.2. 连续小波变换（CWT）

为克服 STFT 窗函数固定、时频分辨率不可调的缺陷，Morlet 等

人提出 CWT。其核心创新是采用 “可变尺度小波函数” 作为分析窗，通过调整尺度（对应频率）与时间平移，实现对信号不同时频区域的自适应分析。

• 小波函数约束条件

进行 CWT 前，小波函数 $\Psi(t)$ 需满足两个基本条件，以保证分析有效性与可逆性：

a. 能量单位化： $\int_{-\infty}^{+\infty} |\Psi(t)|^2 dt = 1$ ，确保不同尺度下小波函数能量一致，避免能量差异干扰分析结果；

b. 可容许性条件： $C_\Psi = 2\pi \int_0^{+\infty} \frac{|\hat{\Psi}(\omega)|^2}{\omega} d\omega < \infty$ ，其中 $\hat{\Psi}(\omega)$

为 $\Psi(t)$ 的傅里叶变换，该条件保证 CWT 结果可重构原始信号。

• 数学表达式

连续时间信号 $s(t)$ 的 CWT 表达式为：

$$W_s(a, \tau) = \frac{1}{\sqrt{a}} \int_{-\infty}^{+\infty} s(t) \Psi^* \left(\frac{t - \tau}{a} \right) dt$$

式中， $a > 0$ 为尺度参数（与频率成反比， a 越小对应频率越高），

τ 为时间平移参数， $\Psi^*(\cdot)$ 为母小波函数的复共轭， $\frac{1}{\sqrt{a}}$ 为归一化因子

（保证不同尺度下能量相同）。

母小波函数 $\Psi\left(\frac{t-\tau}{a}\right)$ 由母小波 $\Psi(t)$ 经平移 τ 、伸缩 a 得到，通过调整 a 与 τ 可生成多尺度、多位置的小波基函数族，实现多分辨率分析。

- 尺度与频率的关系

尺度 a 不直接等于频率，需结合母小波的中心频率确定：设母小波的傅里叶变换幅度最大值对应的角频率为 ω_0 （中心角频率），则对应的中心频率（赫兹）为 $f_0 = \frac{\omega_0}{2\pi}$ ，尺度 a 对应的实际频率近似为：

$$f = \frac{f_0}{a}$$

由此可见， a 减小时， f 增大，小波函数时域宽度变窄（时间分辨率提高）； a 增大时， f 减小，小波函数时域宽度变宽（频率分辨率提高），这正是 CWT 实现自适应时频分辨率的核心机制。

- 常用母小波函数

不同母小波的时频特性适配不同信号分析场景：

- **Morlet 小波**：由高斯窗与正弦函数乘积构成，时域局部化好、频域频谱集中，适用于含正弦振荡成分的信号（如机械振动、地震信号）；
- **Daubechies 小波（db 小波）**：具有紧支撑性（时域仅有限区间非零），计算效率高，适用于信号突变点检测与数据压缩（如图像处理、信号去噪）；
- **Haar 小波**：最简单的小波函数，时域为正负对称矩形脉冲，时域分辨率好、频域分辨率低，适用于分析阶跃变化与突变特征。

1.1.3 S 变换 (ST)

Stockwell 等人综合 STFT 与 CWT 的优点提出 S 变换，其核心是采用“与频率相关的变尺度高斯窗”，既保留 STFT 时间 - 频率直接对应、频率轴均匀的优势，又继承 CWT 自适应时频分辨率的特性，同时具备无损可逆性(可从 S 变换结果完全重构原始信号)。

• 数学表达式

连续时间信号 $s(t)$ 的 S 变换表达式为：

$$S_{ST}(\tau, f) = \frac{|f|}{k\sqrt{2\pi}} \int_{-\infty}^{+\infty} s(t) e^{-\frac{(t-\tau)^2 f^2}{2k^2}} e^{-j2\pi f t} dt$$

式中， τ 为时间平移参数， $f \neq 0$ 为频率参数， k 为控制高斯窗宽度的参数， $e^{-\frac{(t-\tau)^2 f^2}{2k^2}}$ 为变尺度高斯窗(随 f 变化)， $\frac{|f|}{k\sqrt{2\pi}}$ 为归一化因子(保证不同频率下窗函数能量相同)。

从表达式可看出 S 变换的时频分辨率特性： f 增大时，高斯窗宽度减小(时间分辨率提高)； f 减小时，窗宽度增大(频率分辨率提高)，与 CWT 一致；同时， f 直接出现在表达式中，频率轴均匀，便于直观理解与定量分析，继承了 STFT 的优势。

• 与 STFT、CWT 的关系

◦ 与 STFT：S 变换可看作窗函数为 $\omega(t, f) = \frac{|f|}{k\sqrt{2\pi}} e^{-\frac{t^2 f^2}{2k^2}}$ 的 STFT，

即 $S_{ST}(\tau, f) = S_F(\tau, f; \omega(t, f))$ ；

◦ 与 CWT：S 变换可视为“与频率相关的变尺度 CWT”，通过

将母小波取为高斯窗与复指数函数的乘积，实现时间 - 频率域直接映射。

- 参数的影响

参数 k 决定高斯窗宽度随频率的变化幅度，对时频分辨率起关键作用：

- k 较小时：窗宽度随 f 变化幅度大，高频段窗更窄（时间分辨率高）、低频段窗更宽（频率分辨率高），自适应能力强；
- k 较大时：窗宽度随 f 变化幅度小，自适应能力减弱，S 变换性能逐渐接近 STFT。

实际应用中，需通过试错法或交叉验证选择 k ，以平衡时间与频率分辨率，匹配信号特性与分析需求。

1.2 二次时频分析方法

二次时频分析方法通过对信号进行二次运算（如信号与其延迟版本的乘积的傅里叶变换）构建时频分布，核心特点是时频分布满足二次型性质 —— 多分量信号的时频分布等于各分量自项（真实时频分布）与分量间交叉项的总和。该类方法理论上可突破 Heisenberg 不确定原理限制，实现理想时频分辨率，但多分量信号分析中的交叉项干扰是主要挑战。以下重点介绍 Wigner-Ville 分布（WVD）及其衍

生的核函数光滑方法。

1.2.1 Wigner-Ville 分布 (WVD)

WVD 由 Wigner 于 1932 年在量子力学领域提出，后经 Ville 引入信号处理，是二次时频分析的经典代表。其核心优势是不依赖窗函数，直接通过信号延迟乘积的傅里叶变换构建时频分布，理论上具有最优时频分辨率，能精准捕捉信号频率的细微时变特征。

• 数学表达式

对于连续时间信号 $x(t)$ ，其 WVD 定义为：

$$\text{WVD}_x(t, f) = \int_{-\infty}^{+\infty} x\left(t + \frac{\tau}{2}\right) x^*\left(t - \frac{\tau}{2}\right) e^{-j2\pi f\tau} d\tau$$

式中， τ 为延迟变量， t 为时间变量， f 为频率变量， $x^*(\cdot)$ 为 $x(t)$ 的复共轭， $\text{WVD}_x(t, f)$ 代表信号在 t 、 f 处的时频能量密度。

计算过程分为两步：首先，计算信号在 t 附近的延迟乘积 $x\left(t + \frac{\tau}{2}\right) x^*\left(t - \frac{\tau}{2}\right)$ ，反映信号在 t 附近、延迟 τ 范围内的相关性；其次，对延迟乘积做傅里叶变换（关于 τ ），将延迟域信息转换为频率域信息，得到 t 处的频率分布。

• 单分量信号的 WVD 特性

对单分量信号（如正弦信号、调频信号），WVD 具有优异的时频聚集性，能量能准确集中在信号真实时频轨迹上。例如，单分量调频信号 $x(t) = \cos(2\pi(f_0 t + kt^2))$ （ f_0 为初始频率， k 为调频系数），其

WVD 能量主要集中在频率轨迹 $f = f_0 + 2kt$ 上，时频分布清晰，无交叉项干扰，能精准反映频率随时间的线性变化规律。

• 多分量信号的交叉项问题

当信号含多个分量时，WVD 的二次型性质会导致时频分布中出现交叉项，这是其实际应用的主要瓶颈。设信号 $x(t) = x_1(t) + x_2(t)$ ($x_1(t)$ 、 $x_2(t)$ 为独立分量)，其 WVD 可展开为：

$$WVD_x(t, f) = WVD_{x_1}(t, f) + 2\text{Re}[WVD_{x_1, x_2}(t, f)] + WVD_{x_2}(t, f)$$

式中， $WVD_{x_1}(t, f)$ 、 $WVD_{x_2}(t, f)$ 为分量自项（真实时频分布）， $WVD_{x_1, x_2}(t, f) = \int_{-\infty}^{+\infty} x_1\left(t + \frac{\tau}{2}\right) x_2^*\left(t - \frac{\tau}{2}\right) e^{-j2\pi f\tau} d\tau$ 为交叉项， $\text{Re}[\cdot]$ 表示取复部。

交叉项具有三大特性：

- a. 振荡性：在时频平面呈周期性振荡，振荡频率与两分量频率差正相关，频率差越大振荡越剧烈；
- b. 虚假性：时频位置通常位于两自项之间，不对应信号真实频率成分，易导致假频、模糊；
- c. 高能量：能量可能与自项相当甚至更高，严重掩盖自项，影响分析准确性。

对于含 n 个分量的信号，交叉项数量为 $C_n^2 = \frac{n(n-1)}{2}$ ，随分量数增

加呈平方增长，时频分布可读性急剧下降。

1.2.2 WVD 衍生的核函数光滑方法

为解决 WVD 的交叉项问题，研究人员提出一系列核函数光滑方法，通过引入核函数对 WVD 进行平滑处理，在抑制交叉项的同时尽可能保留自项的时频聚集性。主要包括 Cohen 类分布、仿射类分布、自适应最优核方法与能量再分配方法。

(1) Cohen 类分布

Cohen 于 1966 年提出 Cohen 类分布，核心思想是在 WVD 积分表达式中引入二维核函数 $\Phi(\tau, \nu)$ （通常与 t 、 f 无关），对 WVD 进行平滑，从而抑制交叉项。

• 数学表达式

Cohen 类分布的一般形式为：

$$C_x(t, f) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} \Phi(\tau, \nu) x\left(t + \frac{\tau}{2}\right) x^*\left(t - \frac{\tau}{2}\right) e^{-j2\pi(f\tau - t\nu)} d\tau d\nu$$

对核函数 $\Phi(\tau, \nu)$ 做二维傅里叶变换（记为 $K(\theta, \tau)$ ），可简化为：

$$C_x(t, f) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} K(\theta, \tau) WVD_x(t - \theta, f - \tau) d\theta d\tau$$

该形式清晰体现 Cohen 类分布是对 WVD 在时间（ θ ）与频率（ τ ）方向的二维平滑结果。

• 常用 Cohen 类分布成员

- 矩形核 Cohen 类分布（如 Born-Jordan 分布）：核函数为矩形

窗，对 WVD 做均匀平滑，交叉项抑制效果好，但自项时频分辨率降低；

- 高斯核 Cohen 类分布（如 Choi-Williams 分布）：核函数为高斯窗，对 WVD 做高斯加权平滑，交叉项抑制与自项分辨率平衡效果好，是实际应用中最常用的类型；

- Bessel 核 Cohen 类分布：核函数为 Bessel 函数，时频局部化特性优，适用于快速时变信号分析，但计算复杂度高。

- **核函数选择原则**

核函数的支撑范围决定平滑效果与分辨率的平衡：支撑范围宽时，平滑强、交叉项抑制好，但分辨率低；支撑范围窄时，平滑弱、分辨率高，但交叉项抑制差。需根据信号特性（分量数、频率间隔、时变速率）与分析需求（优先分辨率或交叉项抑制）选择核函数。

(2) 仿射类分布

仿射类分布适用于分析具有尺度不变性的信号（如自相似信号、分形信号），其核函数满足“仿射变换不变性”——对信号的时间尺度伸缩与平移变换具有不变性，能更好适配信号尺度变化特性。

- **核函数约束条件**

仿射类分布的核函数 $K(\tau, \nu)$ 需满足仿射不变性：

$$K(a\tau, \frac{v}{a}) = |a|K(\tau, v) \quad (\forall a > 0)$$

其中 a 为尺度伸缩因子，确保核函数在信号尺度变化时仍能保持稳定的平滑效果。

- 数学表达式

仿射类分布的具体形式为：

$$A_x(t, f) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} K(\tau, v) x\left(t + \frac{\tau}{2}\right) x^*\left(t - \frac{\tau}{2}\right) e^{-j2\pi(ft - tv)} d\tau dv$$

与 Cohen 类分布相比，核心差异在于核函数额外满足仿射不变性，使其对尺度变化信号的适应性更强。

- 常用仿射类分布成员

- 仿射 Wigner 分布 (Affine Wigner Distribution, AWD)：在 WVD

基础上引入仿射核函数，将时间 - 频率域分析转换为时间 - 尺度域分析，对信号的尺度变化（如频率线性缩放）具有不变性，适用于分析语音信号（如元音频率随语速的尺度变化）、超声回波信号（如不同深度反射信号的尺度差异）；

- 小波 Wigner 分布 (Wavelet Wigner Distribution, WWD)：结合

小波变换与 WVD 的优势，以小波函数替代传统傅里叶基，通过仿射核函数实现对非平稳、尺度变化信号的高分辨率分析，在生物医学信号（如脑电信号的节律尺度变化）分析中应用广泛；

- 尺度图 (Scalogram)：本质是仿射类分布的简化形式，通过对小波变换结果取模平方得到，虽分辨率略低于 AWD 与 WWD，但计算复杂度低，可快速实现对尺度变化信号的定性分析。

- 仿射类分布的优势与局限

优势在于对尺度变化信号的适应性强，能有效捕捉信号在不同尺度下的时频特征，避免因信号尺度伸缩导致的时频分布偏移；局限是核函数设计复杂，需严格满足仿射不变性，且对非尺度变化的多分量信号，交叉项抑制效果不如 Cohen 类分布，实际应用中需结合信号是否含尺度变化特性选择。

(3) 自适应最优核方法 (Adaptive Optimal Kernel, AOK)

传统核函数光滑方法（如 Cohen 类、仿射类）采用固定核函数，无法根据信号局部时频特征动态调整平滑强度，导致在信号时频变化剧烈区域（如突变点、多分量交叉区域）易出现“过平滑”（分辨率损失）或“欠平滑”（交叉项残留）。自适应最优核方法通过“动态调整核函数支撑范围”解决这一问题，核心是让核函数根据信号局部时频特性自动优化，实现“自项保留 - 交叉项抑制”的动态平衡。

- 核心思想与实现逻辑

AOK 的实现分为三步：

a. 局部时频特征估计：首先计算信号的初始时频分布（如粗分辨率 WVD 或 STFT），通过滑动窗口分析每个时频点 (t, f) 周围的信号能量分布，判断该区域是“自项主导区”（能量集中、无振荡）还是“交叉项主导区”（能量分散、周期性振荡）；

b. 核函数动态优化：对自项主导区，选择窄支撑核函数（弱平滑），保留自项的高分辨率；对交叉项主导区，选择宽支撑核函数（强平滑），抑制交叉项振荡；核函数支撑范围的优化目标是最小化“自项分辨率损失”与“交叉项能量残留”的加权和：

$$J(K) = \alpha \cdot \text{Loss}_{\text{resolution}}(K) + (1 - \alpha) \cdot \text{Residual}_{\text{cross}}(K)$$

其中 $\alpha \in [0, 1]$ 为平衡系数， $\text{Loss}_{\text{resolution}}(K)$ 为自项分辨率损失，

$\text{Residual}_{\text{cross}}(K)$ 为交叉项能量残留；

c. 最优时频分布构建：用优化后的核函数对初始时频分布进行平滑，得到最终的自适应时频分布。

• 数学表达式

AOK 的时频分布形式为：

$$\text{AOK}_x(t, f) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} K_{\text{opt}}(t, f; \theta, \tau) \text{WVD}_x(t - \theta, f - \tau) d\theta d\tau$$

式中， $K_{\text{opt}}(t, f; \theta, \tau)$ 为自适应最优核函数，其支撑范围随 (t, f) 变化——在自项主导区，支撑范围 $(\theta_{\text{max}}, \tau_{\text{max}})$ 小；在交叉项主导区，支撑范围大。

(4) 能量再分配方法 (Energy Reassignment Method, ERM)

能量再分配方法的核心思路与核函数光滑不同：不通过平滑抑制交叉项，而是通过“重新分配时频能量的位置”，将交叉项的虚假能量迁移到自项的真实时频位置，同时增强自项能量的聚集性，从根本上解决交叉项干扰问题。

• 核心原理

基于“时频能量重心”概念：对时频分布中每个时频点 (t, f) ，计算其周围局部区域内能量的“时间重心” $t_c(t, f)$ 与“频率重心” $f_c(t, f)$ ，将该点的能量迁移到 $(t_c(t, f), f_c(t, f))$ 处，实现能量的重新分配——自项区域的能量重心接近真实时频位置，迁移后能量更集中；交叉项区域的能量重心分散，迁移后虚假能量被拆分并融入自项，或因能量分散被弱化。

• 数学表达式（以 WVD 为例）

对 WVD 的能量再分配过程分为两步：

a. 计算每个时频点 (t, f) 的时间重心与频率重心：

$$t_c(t, f) = t + \frac{\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} \theta \cdot |WVD_x(t - \theta, f - \tau)|^2 d\theta d\tau}{\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} |WVD_x(t - \theta, f - \tau)|^2 d\theta d\tau}$$
$$f_c(t, f) = f + \frac{\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} \tau \cdot |WVD_x(t - \theta, f - \tau)|^2 d\theta d\tau}{\int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} |WVD_x(t - \theta, f - \tau)|^2 d\theta d\tau}$$

式中， θ 、 τ 为局部窗口内的时间偏移与频率偏移，分子为能量加权偏

移总和，分母为局部区域总能量， $t_c(t, f)$ 、 $f_c(t, f)$ 即能量重心坐标。

b. 构建再分配时频分布：

$$ERM_x(t, f) = \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} |WVD_x(\theta, \tau)|^2 \cdot \delta(t - t_c(\theta, \tau)) \cdot \delta(f - f_c(\theta, \tau)) d\theta d\tau$$

式中， $\delta(\cdot)$ 为狄拉克函数，仅当 $(t, f) = (t_c(\theta, \tau), f_c(\theta, \tau))$ 时取值非零，实现能量从 (θ, τ) 到 $(t_c(\theta, \tau), f_c(\theta, \tau))$ 的迁移。

1.3 自适应性非参数时频分析方法

自适应性非参数时频分析方法是在“非参数统计”框架下，通过数据驱动的方式动态调整时频分析策略，无需预设固定的变换基（如傅里叶基、小波基）或核函数参数，核心特点是“完全依赖数据特征优化分析过程”，能最大程度适配信号的非平稳、非线性特性，尤其适用于未知信号或复杂动态系统信号的分析。

1.3.1 局部多项式时频分布（LPTFD）

LPTFD 基于“局部多项式回归”思想，通过在每个时频点周围的局部窗口内，用多项式拟合信号的时频特征（如瞬时频率、瞬时幅度），构建非参数化的时频分布，无需依赖预设的变换基或核函数，完全由数据驱动。

• 核心原理

信号的瞬时频率 $f(t)$ 与瞬时幅度 $A(t)$ 是描述非平稳信号时频特征

的核心参数, LPTFD 通过以下步骤估计这两个参数并构建时频分布:

- a. 局部窗口选择: 对任意时间 t_0 , 选择以 t_0 为中心的局部窗口 $[t_0 - h, t_0 + h]$ (h 为窗口宽度, 通过交叉验证自适应选择);
- b. 局部多项式拟合: 在窗口内, 用 p 次多项式拟合信号的相位函数 $\phi(t)$ (信号可表示为 $s(t) = A(t)e^{j\phi(t)}$):

$$\hat{\phi}(t; t_0) = \sum_{k=0}^p a_k (t - t_0)^k$$

其中 a_k 为多项式系数,

通过最小化窗口内信号相位的拟合误差 $\sum_{t \in [t_0 - h, t_0 + h]} |\phi(t) - \hat{\phi}(t; t_0)|^2$ 求解;

- a. 瞬时频率与幅度估计: 瞬时频率为相位的一阶导数, 即 $\hat{f}(t_0) = \frac{1}{2\pi} \hat{\phi}'(t_0) = \frac{1}{2\pi} a_1$; 瞬时幅度通过窗口内信号幅度的加权平均估计:

$$\hat{A}(t_0) = \frac{1}{|\text{window}|} \sum_{t \in [t_0 - h, t_0 + h]} w(t - t_0) A(t) \quad (w(\cdot)$$

- b. 为加权函数, 如高斯权重);
- c. 时频分布构建: 将每个时间 t_0 的 $\hat{A}(t_0)$ 与 $\hat{f}(t_0)$ 对应, 形成时频能量分布: $\text{LPTFD}_s(t, f) = \hat{A}(t)^2 \cdot \delta(f - \hat{f}(t))$, 实际应用中常用高斯窗替代狄拉克函数, 避免能量过于集中导致的噪声敏感。

- 数学表达式（连续时间信号）

局部多项式相位拟合的优化目标为：

$$\min_{a_0, a_1, \dots, a_p} \int_{t_0-h}^{t_0+h} w\left(\frac{t-t_0}{h}\right) \left| \text{Arg}(s(t)) - \sum_{k=0}^p a_k (t-t_0)^k \right|^2 dt$$

式中， $\text{Arg}(\cdot)$ 为取复信号的相位， $w(\cdot)$ 为紧支撑权重函数（如 Epanechnikov 权重）， h 为窗宽（平滑参数），通过交叉验证选择 h 以最小化相位拟合的均方误差。

瞬时频率估计为：

$$\hat{f}(t_0) = \frac{1}{2\pi} \cdot \frac{\int_{t_0-h}^{t_0+h} w\left(\frac{t-t_0}{h}\right) \cdot \frac{d}{dt} \text{Arg}(s(t)) \cdot (t-t_0) dt}{\int_{t_0-h}^{t_0+h} w\left(\frac{t-t_0}{h}\right) \cdot (t-t_0)^2 dt}$$

该式通过加权最小二乘法求解一阶多项式系数 a_1 ，进而得到瞬时频率。

- 关键参数与性能影响

- 多项式阶数 p : $p = 1$ （线性拟合）适用于频率缓慢变化的信号（如慢调频信号）； $p = 2$ （二次拟合）适用于频率快速变化的信号（如急变调频信号）； p 过高易导致过拟合， p 过低易导致欠拟合，需通过 AIC（赤池信息准则）或 BIC（贝叶斯信息准则）选择；
- 窗宽 h : h 过大时，局部窗口包含过多时变信息，拟合精度下降； h 过小时，窗口内样本量不足，估计方差增大，通常通过交叉验证（如 K 折交叉验证）选择最优 h ；

- 权重函数 $w(\cdot)$: Epanechnikov 权重（抛物线形）的局部平滑效果最优，高斯权重的鲁棒性强（对异常值不敏感），矩形权重计算简单但平滑效果差，需根据信号噪声水平选择。

1.3.2 自适应非参数核估计方法（ANKE）

ANKE 基于非参数核密度估计理论，通过自适应调整核函数的带宽（平滑参数）与形状，构建信号的时频分布，核心是“用核函数的局部加权求和替代固定基变换”，实现对信号时频特征的柔性拟合。

• 核心原理

传统非参数核估计（如 Parzen 窗估计）采用固定带宽核函数，无法适配信号时频特征的局部变化；ANKE 通过以下改进实现自适应：

- 局部带宽自适应：对每个时频点 (t, f) ，根据该点周围信号的能量密度调整核带宽 —— 能量密度高的区域（自项主导区）选择窄带宽（高分辨率），能量密度低的区域（交叉项或噪声区）选择宽带宽（强平滑）；
- 核形状自适应：根据信号局部时频特征的对称性（如自项能量呈对称分布，交叉项呈非对称振荡分布）调整核形状 —— 对称区域用对称核（如高斯核），非对称区域用非对称核（如偏态高斯核），提升拟合精度。

- 数学表达式

设信号的短时傅里叶变换为 $\text{STFT}_s(t, f)$ （作为初始时频特征），

ANKE 的时频分布为：

$$\text{ANKE}_s(t, f) = \sum_{i=1}^N \sum_{j=1}^M \text{STFT}_s(t_i, f_j) \cdot K\left(\frac{t - t_i}{h_t(t_i, f_j)}, \frac{f - f_j}{h_f(t_i, f_j)}\right)$$

式中， N 、 M 为时间与频率采样点数， (t_i, f_j) 为采样时频点， $h_t(t_i, f_j)$ 、 $h_f(t_i, f_j)$ 为自适应时间带宽与频率带宽（随 (t_i, f_j) 变化）， $K(\cdot, \cdot)$ 为自适应核函数（形状随局部特征变化）。

自适应带宽的计算基于局部能量梯度：

$$h_t(t, f) = h_0 \cdot \left(\frac{1}{1 + \nabla_t E(t, f)}\right)^\alpha, \quad h_f(t, f) = h_0 \cdot \left(\frac{1}{1 + \nabla_f E(t, f)}\right)^\alpha$$

其中 h_0 为初始带宽， $\nabla_t E(t, f)$ 、 $\nabla_f E(t, f)$ 为时间与频率方向的能量梯度（反映时频特征变化率）， $\alpha \in (0, 1]$ 为调整系数，能量梯度越大，带宽越小。

1.3.3 基于机器学习的自适应时频分析方法

随着机器学习技术的发展，基于数据驱动的自适应时频分析方法成为新方向。这类方法通过训练模型学习信号时频特征与分析策略的映射关系，实现“端到端”的自适应时频分布构建，核心是用模型替代传统方法中的人工参数设计与规则定义，典型代表包括基于卷积神经网络（CNN）的自适应时频映射、基于 Transformer 的动态时频

分析、基于强化学习的时频参数优化。

(1) 基于 CNN 的自适应时频映射

- 核心原理：利用 CNN 的局部特征提取能力，将原始信号（或初始时频特征，如 STFT）作为输入，通过卷积层自动学习信号的时频纹理特征（如自项的聚集性、交叉项的振荡模式），再通过全连接层输出优化后的时频分布。关键创新是引入 “时频注意力机制”——在 CNN 中加入注意力模块（如 SE 注意力、CBAM 注意力），让模型自动聚焦于信号的有效时频区域（自项主导区），抑制噪声与交叉项干扰。
- 实现流程：
 - a. 数据预处理：将原始信号切片为固定长度的样本，计算每个样本的初始时频特征（如 STFT 矩阵），并标注对应的 “理想时频分布”（如无交叉项的 WVD、人工标注的真实时频轨迹）作为监督信号；
 - b. 模型训练：构建 CNN 模型，输入为初始时频特征矩阵，输出为与输入尺寸一致的优化时频分布矩阵，损失函数采用均方误差（MSE）：

$$\mathcal{L} = \frac{1}{H \times W} \sum_{i=1}^H \sum_{j=1}^W |Y_{i,j} - \hat{Y}_{i,j}|^2$$

其中 H 、 W 分别为时间与频率维度的像素数， $Y_{i,j}$ 为理想时频分布的像素值， $\hat{Y}_{i,j}$ 为模型输出的像素值；

- c. 自适应分析：训练完成后，输入新信号的初始时频特征，模型可自动输出优化后的时频分布，无需人工调整任何参数。

(2) 基于 Transformer 的动态时频分析

- 核心原理：针对 CNN 难以捕捉长距离时频依赖的缺陷（如多分量信号的跨区域交叉项），引入 Transformer 的自注意力机制，让模型学习时频平面上任意两点的关联关系，动态调整不同区域的分析权重。例如，通过自注意力计算时频点 (t_1, f_1) 与 (t_2, f_2) 的关联系数，若二者属于同一自项的不同部分，赋予高权重以增强关联；若属于交叉项与自项，赋予低权重以抑制干扰。
- 数学表达（简化版）：

设输入的初始时频特征矩阵为 $X \in \mathbb{R}^{L \times D}$ （ $L = H \times W$ 为展平后的时频点数量， D 为每个时频点的特征维度），通过自注意力计算得到注意力权重矩阵 $A \in \mathbb{R}^{L \times L}$ ：

$$A_{i,j} = \frac{\exp(Q_i \cdot K_j^T / \sqrt{D_k})}{\sum_{k=1}^L \exp(Q_i \cdot K_k^T / \sqrt{D_k})}$$

其中 $Q = XW_Q$ 、 $K = XW_K$ 分别为查询矩阵与键矩阵， W_Q 、 W_K 为可学习参数， D_k 为键矩阵的维度，用于缩放注意力得分。最终的时频特征

通过注意力加权得到：

$$\hat{\mathbf{X}} = \mathbf{A} \cdot \mathbf{V}$$

其中 $\mathbf{V} = \mathbf{XW}_V$ 为值矩阵， $\hat{\mathbf{X}}$ 展平后即为优化后的时频分布矩阵。

- 优势与局限：优势在于能捕捉长距离时频依赖，对多分量、复杂交叉项信号的分析效果优于 CNN；模型泛化能力强，训练完成后可适配不同类型的非平稳信号。局限在于计算复杂度极高（自注意力的时间复杂度为 $O(L^2)$ ），对硬件资源要求高；训练需大量标注数据，小样本场景下性能下降明显。

(3) 基于强化学习的时频参数优化

- 核心原理：将时频分析参数的调整视为 “强化学习任务” —— 智能体 (Agent) 的动作是调整分析参数（如 STFT 的窗宽、WVD 的核函数支撑范围），环境是待分析的信号，奖励函数是时频分布的质量评估指标（如自项分辨率、交叉项抑制率），通过试错学习找到最优的参数组合。
- 关键组件设计：
 - a. 状态 (State)：定义为当前信号的局部特征（如信号的瞬时幅度、频率变化率）与当前参数下的时频分布评估指标；
 - b. 动作 (Action)：参数调整的离散或连续动作，如窗宽在 $\{32, 64, 128\}$ 中选择（离散）、核函数支撑范围在 $[0.1, 1.0]$ 内连续

调整；

- c. 奖励（**Reward**）：设计复合奖励函数，综合考虑分辨率与抑制效果：

$$R = \alpha \cdot \text{Res}(Y) - (1 - \alpha) \cdot \text{Cross}(Y)$$

其中 $\text{Res}(Y)$ 为自项分辨率得分（值越大越好）， $\text{Cross}(Y)$ 为交叉项能量占比（值越小越好）， $\alpha \in [0,1]$ 为平衡系数。

2 多特征预示人工智能预测经典算法研究

在多特征预示人工智能预测经典算法研究范畴中，基于统计的、基于神经网络的及基于 **SVM** 的时间序列模型是核心研究载体。时间序列建模作为一个兼具动态性与前沿性的研究领域，过去数十年间持续受到学术界的高度关注。其核心目标在于针对多特征场景下的时间序列，通过系统收集并深度剖析过往观测数据，构建适配模型以揭示序列在多特征交互影响下的固有结构，进而依托该模型生成未来序列值——即实现多特征驱动的预测。因此，时间序列预测可界定为通过解析多特征作用下的历史规律来预判未来趋势的智能行为。鉴于其在商业决策、经济分析、金融风控、科学实验、工程优化等众多实际领域中多特征预示场景的关键价值，实际应用中需审慎选取适配的时间序列预测模型及算法。多年来，研究人员围绕提升多特征预示精度与模型鲁棒性开展了大量探索，致力于开发高效的人工智能预测模型。

现结合项目技术指标要求，针对上述经典算法中适配多特征预示场景的核心方法展开重点研究。

2.1 决策树(DT)

决策树（Decision Tree, DT）是一种基于树状拓扑结构的贪心归纳算法，通过递归划分多特征空间实现从输入到输出的映射。其核心优势在于对多特征的“白盒”式处理能力——决策路径可直接解释特征对预测结果的影响机制，因此在需要可解释性的多特征预示场景（如医疗诊断、金融风控）中应用广泛。

2.1.1 核心原理与数学模型

决策树的构建过程是一个从根节点到叶节点的递归分裂过程，每个分裂步骤均以“最大化信息增益”或“最小化不纯度”为目标。具体包括以下关键步骤：

(1) 节点分裂准则

对于分类任务，常用信息熵（Entropy）和基尼指数（Gini Index）衡量节点不纯度；对于回归任务，均方误差（MSE）和平均绝对误差（MAE）是主要指标。

- 信息熵（Entropy）：描述样本集合的混乱程度，计算公式为：

$$H(D) = - \sum_{k=1}^K p_k \log_2 p_k$$

其中， D 为当前节点的样本集合， K 为目标变量的类别数， $p_k = \frac{|D_k|}{|D|}$ 表示第 k 类样本在 D 中的占比。信息熵越小，样本集合越“纯”（即多数样本属于同一类别）。

- 基尼指数 (Gini Index)：衡量随机抽取两个样本时类别不一致的概率，计算公式为：

$$\text{Gini}(D) = 1 - \sum_{k=1}^K p_k^2$$

基尼指数取值范围为 $[0,1)$ ，值越小表示节点纯度越高。

- 均方误差 (MSE)：回归任务中衡量节点分裂效果的指标，计算公式为：

$$\text{MSE}(D) = \frac{1}{|D|} \sum_{i \in D} (y_i - \bar{y}_D)^2$$

其中， y_i 为样本 i 的真实值， $\bar{y}_D = \frac{1}{|D|} \sum_{i \in D} y_i$ 为当前节点样本的均值。

MSE 越小，节点内样本的预测误差越集中。

- 信息增益 (Information Gain)：父节点与子节点的不纯度差值，用于选择最优分裂特征，计算公式为：

$$\text{IG}(D, a) = H(D) - \sum_{v=1}^V \frac{|D_v|}{|D|} H(D_v)$$

其中， a 为候选分裂特征， V 为特征 a 的取值个数， D_v 为特征 a 取值为 V 的样本子集。信息增益越大，说明特征 a 对降低节点不纯度的贡

献越显著。

(2) 树的剪枝策略

为避免过拟合（即树结构过于复杂导致对训练数据的“记忆”而非“学习”），决策树需进行剪枝处理，分为预剪枝和后剪枝：

- 预剪枝：在树的生长过程中设置停止条件（如最大深度、最小样本数、最小信息增益），提前终止分裂；
- 后剪枝：先构建完整决策树，再通过交叉验证删除对泛化性能无增益的分支（如代价复杂度剪枝）。

2.1.2 多特征处理机制

决策树对多特征的处理具有天然适配性，具体体现在：

- 特征优先级自动排序：通过信息增益或基尼指数的计算，算法可自主识别对预测结果影响显著的特征（如在房价预测中，“面积”“地段”通常比“装修风格”具有更高的分裂优先级）；
- 非线性关系捕捉：无需对特征进行线性转换，可直接通过多轮分裂拟合特征与目标变量的非线性关联（如“当温度 $> 30^{\circ}\text{C}$ 且湿度 $> 80\%$ 时，设备故障概率骤增”）；
- 特征尺度不敏感：数值型特征（如年龄）与类别型特征（如性别）可直接输入，无需归一化或标准化处理。

2.1.3 典型应用案例

在多特征预示场景中，决策树的可解释性使其成为首选模型之一：

- 医疗风险预测：通过 “年龄” “血压” “血糖” 等特征构建决策树，可直观输出 “当年龄 > 60 岁且收缩压 > 140mmHg 时，中风风险提升 30%” 等决策规则；
- 客户流失预警：基于 “消费频率” “客服投诉次数” “会员等级” 等特征，决策树可生成阶梯式预警规则，辅助企业制定精准挽留策略。

2.1.4 性能优化与局限

(1) 优化方向

- 结合领域知识调整分裂准则（如在故障预测中，对 “故障样本” 赋予更高权重）；
- 采用集成剪枝策略（如结合预剪枝与后剪枝，平衡树的复杂度与泛化能力）。

(2) 局限性

- 对噪声数据敏感，少量异常值可能导致树结构剧烈变化；
- 倾向于选择取值较多的特征(如 ID 类特征),可能引入伪相关性；
- 单棵树泛化能力有限，在高维特征场景下易过拟合。

2.2 随机森林 (RF)

随机森林 (Random Forest, RF) 是 Breiman 于 2001 年提出的集成学习算法，通过 Bootstrap 抽样构建多棵决策树并融合其预测结果，解决了单棵决策树泛化能力弱的问题。在多特征预示中，随机森林不

仅保留了决策树对非线性关系的捕捉能力，还通过 “随机性” 提升了模型的稳定性和抗过拟合能力，成为工业界常用的 “瑞士军刀” 模型。

2.2.1 核心原理与数学模型

随机森林的构建基于 “bagging”（Bootstrap Aggregating）集成思想，包含三个关键步骤：

(1) 样本随机性（Bootstrap 抽样）

从原始数据集 D （含 n 个样本）中有放回地抽取 n 个样本，生成 T 个训练子集 $D_1, D_2, \dots, D_T$ （ T 为树的数量）。每个子集用于训练一棵决策树，未被抽取的样本（约占 37%）称为 “袋外数据（OOB）”，可用于无额外验证集的模型评估。

(2) 特征随机性（随机子空间）

每棵树在分裂时，从 m 个特征中随机选取 k 个特征（通常 $k = \sqrt{m}$ 或 $k = m/2$ ）作为候选分裂特征，进一步降低树间相关性。例如，在包含 100 个特征的数据集上，每棵树仅基于 10 个随机特征生长，使模型更关注特征的全局重要性而非局部噪声。

(3) 预测结果融合

对于回归任务，随机森林的最终预测值为所有树预测结果的均值：

$$\hat{y}(x) = \frac{1}{T} \sum_{t=1}^T f_t(x)$$

其中， $f_t(x)$ 为第 t 棵树对样本 x 的预测值。

2.2.2 多特征重要性评估

随机森林的独特优势在于可量化多特征对预测结果的贡献度，常用评估指标包括：

(1) OOB 误差增加率

对特征 j ，随机打乱其在 OOB 样本中的取值，计算打乱前后的预测误差差：

$$\text{Importance}(j) = \frac{1}{T} \sum_{t=1}^T \frac{\text{MSE}_{t,j}^{\text{shuffled}} - \text{MSE}_{t,j}^{\text{original}}}{\text{MSE}_{t,j}^{\text{original}}}$$

其中， $\text{MSE}_{t,j}^{\text{original}}$ 为第 t 棵树在原始 OOB 数据上的 MSE， $\text{MSE}_{t,j}^{\text{shuffled}}$ 为特征 j 被打乱后的 MSE。差值越大，特征 j 的重要性越高。

(2) 节点分裂贡献度

统计特征 j 在所有树中作为分裂特征的总次数，或其降低的不纯度总和，衡量其在分裂过程中的全局贡献。

2.2.3 多特征场景下的参数优化

随机森林的性能高度依赖参数设置，针对多特征场景的关键参数包括：

- 树的数量：增加 T 可降低方差（提升稳定性），但计算成本线性增加，实际应用中通常取 $100 \leq T \leq 500$ ；
- 最大特征数：对高维特征（如 $m > 1000$ ），建议 $k = \log_2 m$ 以避免过拟合；对低维特征， $k = \sqrt{m}$ 可保留更多特征信息；

- 树的深度（`max_depth`）：在噪声较多的多特征数据中，限制深度（如 `max_depth = 20`）

可防止过拟合；在特征与目标变量关系明确的场景中，可设置为“无限制” 以充分学习特征模式。

2.2.4 典型应用与性能对比

(1) 应用案例

- 电力负荷预测：融合 “历史负荷” “气温” “节假日” “风速” 等多特征，随机森林可有效捕捉季节性与突发性因素的综合影响，预测精度较单棵决策树提升 15%-20%；
- 产品质量预示：基于 “原材料成分” “生产温度” “设备转速” 等特征，随机森林可识别关键工艺参数的交互作用，提前预警不合格品风险。

(2) 与决策树的性能对比

指标	决策树（DT）	随机森林（RF）
泛化能力	弱（易过拟合）	强（集成效应降低方差）
计算效率	快（单棵树）	较慢（多棵树并行训练可缓解）
可解释性	高（决策路径直观）	中（依赖特征重要性评估）
多特征适配性	中（易受冗余特征干扰）	高（特征随机性过滤噪声）

2.3 支持向量机 (SVM)

支持向量回归（Support Vector Regression, SVR）是支持向量机

(SVM)在回归任务中的扩展，其核心思想是通过核函数将多特征空间的非线性问题映射到高维线性空间，再构建最优回归超平面。SVR在小样本、高维特征的预示场景中表现优异，尤其适用于特征间存在复杂交互关系的场景（如化学分子活性预测、金融波动预警）。

2.3.1 核心原理与数学模型

SVR 的目标是找到一个回归函数 $f(x) = w \cdot \phi(x) + b$ ，使尽可能多的样本落在 “ ϵ -不敏感间隔带” 内（即允许误差不超过 ϵ ），同时使超平面的复杂度（ $\|w\|^2$ ）最小化。其数学模型可表示为：

(1) 原始优化问题

$$\min_{w,b,\xi,\xi^*} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n (\xi_i + \xi_i^*) \text{ 约束条件:}$$

$$y_i - (w \cdot \phi(x_i) + b) \leq \epsilon + \xi_i \quad (1)$$

$$(w \cdot \phi(x_i) + b) - y_i \leq \epsilon + \xi_i^* \quad (2)$$

$$\xi_i \geq 0, \xi_i^* \geq 0 \quad (i = 1, 2, \dots, n) \quad (3)$$

其中：

- w 为高维空间的权重向量， b 为偏置项；
- $\phi(x_i)$ 为特征映射函数，将原始特征 x_i 映射到高维空间；
- ϵ 为不敏感间隔带宽度（控制允许的误差范围）；
- C 为惩罚系数（平衡模型复杂度与误差容忍度， C 越大对超出间隔带的样本惩罚越重）；
- ξ_i, ξ_i^* 为松弛变量（分别表示样本在间隔带下方和上方的误差）。

(2) 核函数与对偶问题

由于高维映射 $\phi(x)$ 难以显式计算，SVR 通过核函数 $K(x_i, x_j) = \phi(x_i) \cdot \phi(x_j)$ 隐式实现高维空间的内积运算。常用核函数包括：

- 线性核： $K(x_i, x_j) = x_i \cdot x_j$ （适用于特征与目标变量呈线性关系的场景）；
- 径向基核（RBF）： $K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2)$ （ $\gamma > 0$ ，适用于非线性关系， γ 控制核函数的局部性）；
- 多项式核： $K(x_i, x_j) = (x_i \cdot x_j + c)^d$ （ $c \geq 0, d$ 为阶数，适用于特征具有多项式关联的场景）。

通过拉格朗日对偶变换，SVR 的预测公式可表示为：

$$\hat{y}(x) = \sum_{i=1}^n (\alpha_i - \alpha_i^*) K(x_i, x) + b$$

其中， α_i, α_i^* 为拉格朗日乘子，仅支持向量（即落在间隔带外或边界上的样本）对应的乘子非零，大幅降低了计算复杂度。

2.3.2 多特征处理机制与参数优化

(1) 多特征处理机制

- 核函数自适应特征交互：RBF 核可自动捕捉特征间的高阶非线性关联（如“特征 A $\times$ 特征 B”“特征 A²”等），无需人工构造交叉特征；
- 对特征尺度敏感：由于涉及距离计算（如 RBF 核中的 $\|x_i - x_j\|^2$ ），需对多特征进行归一化（如映射至 $[0,1]$ 或 $[-1,1]$ ），避免数值范

围大的特征主导核函数计算。

(2) 参数优化策略

针对多特征场景的关键参数优化策略：

- 根据预测任务的精度要求设置，如在误差允许范围较大的场景（如客流量预测）中取 $\epsilon = 0.1$ ，在高精度要求场景（如传感器误差预测）中取 $\epsilon = 0.01$ ；
- 通过网格搜索（Grid Search）或贝叶斯优化确定，在噪声多的多特征数据中取较小的 C （如 $C = 1$ ），在数据干净的场景中取较大的 C （如 $C = 100$ ）；
- 选择（RBF 核）： γ 越小，核函数的“视野”越广（适合捕捉全局特征模式）； γ 越大，越关注局部特征关联（适合小样本、高维数据）。

2.3.3 典型应用与局限性

(1) 应用案例

- 空气质量预测：融合“PM2.5 浓度”“气象条件”“工业排放数据”等多特征，SVR（RBF 核）可有效捕捉污染物扩散的非线性规律，短期预测误差较线性模型降低 25% 以上；
- 设备剩余寿命预测：基于“振动信号”“温度”“压力”等多传感器特征，SVR 可学习设备退化的隐性模式，提前预警故障风险。

(2) 局限性

- 计算复杂度高,随样本量 n 增长呈 $O(n^3)$ 趋势,不适用于超大规模数据集;
- 对核函数和参数敏感,需大量实验调试;
- 可解释性差,无法直接输出特征对预测结果的影响权重。

2.4 极端树 (ET)

极端树 (Extremely Randomized Trees, ET) 由 Geurts 等于 2006 年提出,是基于随机森林改进的集成学习算法。其核心创新在于通过“极端化”分裂阈值的随机性,在保持多特征预示精度的同时,大幅降低模型训练成本,尤其适配多特征、大规模数据集(如电商实时销量预测、城市交通流量预警),在工业级预测场景中具有显著的效率优势。

2.4.1 核心原理与数学模型

极端树的集成框架与随机森林一致(多棵决策树并行训练 + 结果融合),但在节点分裂机制上存在本质差异,具体原理如下:

(1) 极端化的分裂阈值生成

随机森林需在候选特征的所有可能取值中,通过计算信息增益 / 基尼指数选择“最优分裂阈值”,而极端树完全舍弃最优阈值计算:

- 对每个候选特征,在其取值范围的最小值与最大值之间随机采样生成多个候选阈值(如特征取值为 $[0,50]$ 时,随机生成 12.3、28.7、

41.1 等阈值)；

- 直接选择使节点不纯度(分类任务用基尼指数,回归任务用 MSE)

下降最大的随机阈值进行分裂,无需遍历所有可能取值,单棵树训练时间较随机森林减少 40%-60%。

(2) 样本抽样策略(可选 Bootstrap)

与随机森林必须通过 Bootstrap 抽样生成差异化训练集不同,极端树支持两种样本使用方式:

- 无 Bootstrap 抽样:所有树均使用原始完整数据集训练,仅通过“随机阈值”保证树间多样性,进一步降低抽样带来的计算开销;
- 轻量 Bootstrap 抽样:若数据存在噪声,可采用小比例抽样(如抽取原始样本的 80%),平衡多样性与抗噪性。

(3) 预测结果融合公式

回归任务中,极端树的最终预测值为所有基树预测结果的均值,与随机森林一致:

$$\hat{y}(x) = \frac{1}{T} \sum_{t=1}^T f_t(x)$$

其中, T 为极端树的数量, $f_t(x)$ 为第 t 棵极端树对输入样本 x (含多特征)的预测值。

2.4.2 多特征场景下的核心优势

相较于其他经典算法,极端树在多特征处理中表现出三大核心优

势：

(1) 高维特征处理效率更高

当特征维度 $m > 1000$ （如多传感器监测数据、用户行为画像数据）时，极端树的“随机阈值 + 可选 Bootstrap”机制可避免高维特征下的阈值计算冗余，训练速度通常是随机森林的 2-3 倍，且随特征维度增加，效率优势更显著。

(2) 对冗余特征的鲁棒性更强

多特征场景中常存在冗余特征（如高度相关的“日销售额”与“周销售额”），随机森林可能因重复计算这些特征的分裂增益导致树间相关性上升，而极端树的随机阈值可打破冗余特征的“协同干扰”，使每棵树更关注独立特征的信息，模型泛化误差降低 5%-10%。

(3) 实时更新能力适配动态特征

在多特征动态变化场景（如实时气象预测中“风速”“云层覆盖率”等特征随时间更新），极端树的快速训练特性支持模型分钟级更新，而随机森林因训练耗时较长，难以满足动态特征的实时预示需求。

2.4.3 多特征场景下的参数优化策略

极端树的参数优化需围绕“平衡效率与精度”展开，针对多特征场景的关键参数调整建议如下：

参数名称	作用	多特征场景优化建议
------	----	-----------

树的数量 (T)	影响模型稳定性, T 越大越稳定	建议 $T = 200 - 1000$, 高维特征取上限 (如 800)
最大特征数 (max_features)	控制每棵树的候选特征数	低维特征 ($m < 100$) 取 $m/2$, 高维特征 ($m > 1000$) 取 $\log_2 m$
最小叶节点样本数 (min_samples_leaf)	防止过拟合	多特征 + 噪声数据取 5 - 10, 数据干净时取 1 - 2
随机阈值数量 (n_random_splits)	控制阈值随机性	特征取值离散时取 5 - 10, 连续时取 10 - 20

3 多特征预示人工智能预测多任务回归算法研究

3.1 GroupLasso: 基于 L1/L2 混合范数正则化的多任务学习模型

GroupLasso 模型针对时频谱预示中 “高维输入特征冗余 (如时频域提取的 500+ 维特征)” “多任务共享关键特征” 的需求, 通过 “特征分组正则化” 实现 “无用特征剔除 + 任务共性特征保留”, 尤其适配 160 个振动输出特征的同步预示任务。

3.1.1. 数学框架与参数定义

问题建模: 设多任务学习包含 T 个预示任务 (本项目 $T=160$, 对应 160 个振动输出特征), 输入特征矩阵 $X \in \mathbb{R}^{n \times d}$, 输出矩阵 $Y = [y_1, y_2, \dots, y_T] \in \mathbb{R}^{n \times T}$, 模型参数矩阵 $W = [w_1, w_2, \dots, w_T] \in \mathbb{R}^{d \times T}$ ($w_t \in \mathbb{R}^d$ 为第 t 个任务的特征权重向量)。GroupLasso 的目标函数

为：

$$\min_{\mathbf{W}} \frac{1}{2n} \sum_{t=1}^T \|\mathbf{y}_t - \mathbf{X}\mathbf{w}_t\|_2^2 + \lambda \sum_{g=1}^G \sqrt{|\mathbf{G}_g|} \cdot \|\mathbf{W}_{\mathbf{G}_g, \cdot}\|_2$$

其中：

- 第一项为均方误差损失，衡量模型对所有任务的拟合程度；
- 第二项为 GroupLasso 正则化项， $\lambda > 0$ 为正则化强度（控制稀疏程度，通过 5 折交叉验证选取 $\lambda \in [0.01, 1]$ ）；
- $\mathbf{G} = \{\mathbf{G}_1, \mathbf{G}_2, \dots, \mathbf{G}_G\}$ 为输入特征的分组方式，本项目按“特征类型”分组（如 $\mathbf{G}_1$ 为时域统计特征组、 $\mathbf{G}_2$ 为频域峰 s 值特征组、 $\mathbf{G}_3$ 为时频熵特征组）， $|\mathbf{G}_g|$ 为第 g 组的特征数量；
- $\mathbf{W}_{\mathbf{G}_g, \cdot} \in \mathbb{R}^{|\mathbf{G}_g| \times T}$ 为第 g 组特征对应的所有任务权重子矩阵， $\|\cdot\|_2$ 为 L2 范数。

• 核心参数说明：

- $\mathbf{w}_{g,t}$ ：第 g 组特征在第 t 个任务上的权重向量，若某组特征的 $\|\mathbf{W}_{\mathbf{G}_g, \cdot}\|_2 = 0$ ，则该组特征被整体剔除；
- $\sqrt{|\mathbf{G}_g|}$ ：分组大小惩罚因子，避免“小特征组被过度惩罚”的问题，确保不同规模特征组的正则化强度公平。

3.1.2. 技术优势与实现细节

- 特征分组稀疏机制：正则化项通过 L2 范数约束“组内所有任务的

权重”，若某组特征对所有任务的贡献均较小，则 $\|W_{G_g,:}\|_2$ 趋近于 0，实现“组级稀疏”（整组特征被剔除）；若某组特征对部分任务重要，则保留该组并通过 L2 范数约束任务间的权重差异，促进任务共享关键特征。在本项目测试中，GroupLasso 可将输入特征维度从 500+ 压缩至 100-150 维，特征压缩率 $\geq 70\%$ 。

- **多频段特征同步识别：**通过正则化项的“任务权重共享”特性，自动识别“对多频段振动同时起作用的输入特征”——例如若 G_3 （时频熵特征组）的正则化权重非零且 $\|W_{G_3,:}\|_2$ 较大，说明时频熵特征是 160 个输出特征的共性关键特征，可作为所有频段预示的核心输入。
- **输出特征分组结构可视化：**将输出特征（160 个振动特征）按“频段”分组（如 20-100Hz、100-500Hz 等），计算每组输出特征对应的“核心输入特征组（ $\|W_{G_g,:}\|_2$ 前 5 的特征组）”，绘制“输入特征组 - 输出频段”的关联热力图，直观展示不同频段振动的特征依赖关系。

3.1.3. 工程适配与优化

- **特征分组策略：**避免“分组过大（如将所有特征归为 1 组，退化为普通 L2 正则）”或“分组过小（如每组仅 1 个特征，退化为 L1 正则）”，本项目按“特征的物理意义”分为 8-12 组，每组特

征数量控制在 30-80 维。

- **求解算法：**采用“近端梯度下降法（Proximal Gradient Descent）”

求解目标函数，迭代步长通过线搜索确定，收敛条件设为“两次迭代的目标函数差值 $\leq 1e-6$ ”，确保模型训练稳定。

- **性能对比：**在相同数据集上，GroupLasso 相比普通多任务线性模型，参数数量减少 60%-75%，预测速度提升 2-3 倍，且 160 个任务的平均 RMSE 降低 10%-12%。

3.2 Multitask Wasserstein：基于 Wasserstein 距离正则化的稀疏多任务回归模型

传统多任务学习常用“欧氏距离”度量任务相关性，但欧氏距离仅关注任务输出的均值差异，无法捕捉时频谱预示中“振动信号分布差异（如正常与故障状态下的振动分布不同）”。Multitask Wasserstein 模型引入“Wasserstein 距离”作为任务相关性度量，实现“分布层面的任务知识共享”，显著提升对非平稳振动信号的建模能力。

3.2.1. 核心创新：Wasserstein 距离的引入

- **任务相关性度量改进：**
 - **传统欧氏距离：**衡量两个任务输出均值的差异，即 $d_{\text{Euclid}}(t_1, t_2) = \|\bar{y}_{t_1} - \bar{y}_{t_2}\|_2$ ，忽略输出分布的方差、偏度等信息；

- Wasserstein 距离（2-Wasserstein 距离）：衡量两个概率分布之间的“最优运输成本”，对时频谱预示中常见的高斯分布输出，2-Wasserstein 距离可解析计算为：

$$W_2(P_{t1}, P_{t2}) = \sqrt{\|\mu_{t1} - \mu_{t2}\|_2^2 + \|\Sigma_{t1}^{1/2} - \Sigma_{t2}^{1/2}\|_F^2}$$

其中 $P_{t1} \sim \mathcal{N}(\mu_{t1}, \Sigma_{t1})$ 、 $P_{t2} \sim \mathcal{N}(\mu_{t2}, \Sigma_{t2})$ 分别为第 $t1$ 、 $t2$ 个任务输出的高斯分布， μ_t 为均值向量， Σ_t 为协方差矩阵， $\|\cdot\|_F$ 为 Frobenius 范数。

- 模型目标函数：

$$\min_{W, \{\mu_b, \Sigma_b\}} \frac{1}{2n} \sum_{t=1}^T (\|y_t - Xw_t\|_2^2 + KL(P_t \| \mathcal{N}(Xw_b, \sigma^2 I))) + \frac{\lambda}{2T^2} \sum_{t1=1}^T \sum_{t2=1}^T W_2(P_{t1}, P_{t2})$$

其中：

- 第一项为“拟合损失 + KL 散度损失”，KL 散度约束任务输出分布 P_t 与模型预测分布 $\mathcal{N}(Xw_b, \sigma^2 I)$ (σ^2 为噪声方差) 的接近程度；
- 第二项为 Wasserstein 正则化项，通过最小化所有任务对的 Wasserstein 距离，促进任务输出分布的相似性，实现知识共享；
- W 为任务权重矩阵， $\{\mu_b, \Sigma_b\}$ 为各任务输出的高斯分布参数。

3.2.2. 关键实现步骤

- 输出分布拟合：对每个预示任务 t ，采用“最大似然估计”拟合其

输出 y_t 的高斯分布 $P_t = N(\mu_t, \Sigma_t)$ ，其中 $\mu_t = \frac{1}{n} \sum_{i=1}^n y_{ti}$ ， $\Sigma_t = \frac{1}{n-1} \sum_{i=1}^n (y_{ti} - \mu_t)(y_{ti} - \mu_t)^T$ 。

- **Wasserstein 距离计算**：基于上述解析公式，批量计算所有任务对的 $W_2(P_{t1}, P_{t2})$ ，构建任务相关性矩阵 $D \in \mathbb{R}^{T \times T}$ ($D_{t1, t2} = W_2(P_{t1}, P_{t2})$)。
- **模型训练**：采用“交替优化”策略——固定 $\{\mu_b, \Sigma_b\}$ 优化 W （通过梯度下降），固定 W 更新 $\{\mu_b, \Sigma_b\}$ （通过最大似然估计），迭代至损失函数收敛。

3.2.3. 工程价值与适配场景

- **提升非平稳信号建模能力**：Wasserstein 距离对输出分布的“均值 + 方差”敏感，可捕捉非平稳振动信号的“幅度波动 + 频率漂移”特征，相比传统欧氏距离正则化模型，在非平稳振动测试集上的预测 RMSE 降低 20%-28%。
- **任务聚类与优先级划分**：基于任务相关性矩阵 D ，采用层次聚类将 160 个输出任务分为 5-8 个“高相关性任务簇”（簇内 $W_2 \leq 0.3$ ），对簇内任务采用更强的正则化约束，提升簇内任务的共享效率。
- **噪声鲁棒性**：KL 散度损失可抑制噪声对模型的干扰，当输入信号含 SNR=10dB 的高斯噪声时，模型性能下降幅度 $\leq 10\%$ ，优于传统多任务模型（下降幅度 $\geq 20\%$ ）。

3.3 Reweighted Multitask Wasserstein: 基于 Wasserstein 距离正则

化和 L0.5 稀疏约束的多任务回归模型

Reweighted Multitask Wasserstein 模型在 Multitask Wasserstein 的基础上,引入“L0.5 稀疏约束”,进一步强化“输入特征稀疏性”,解决“GroupLasso 无法实现单特征级稀疏”的问题,适用于“需精准定位关键单特征”的时频谱预示场景(如故障特征的精准识别)。

3.3.1. 模型改进与稀疏策略

- 目标函数改进: 在 Multitask Wasserstein 的目标函数中加入 L0.5 正则化项, 最终目标函数为:

$$\min_{W, \{\mu_t, \Sigma_t\}} \text{Loss}_{\text{Multitask Wasserstein}} + \gamma \sum_{t=1}^T \sum_{i=1}^d |w_{ti}|^{0.5}$$

其中 $\gamma > 0$ 为稀疏正则化强度(通过交叉验证选取 $\gamma \in [0.001, 0.1]$, 平衡稀疏性与拟合精度), w_{ti} 为第 t 个任务中第 i 个输入特征的权重, $|\cdot|^{0.5}$ 为 L0.5 范数。相比 L1 范数($|\cdot|^1$), L0.5 范数具有更强的“稀疏诱导性”——其函数曲线在 $w_{ti} = 0$ 处更陡峭, 能更显著地将微小权重压缩至0, 实现“单特征级稀疏”; 同时避免L0范数(计数非零元素)的NP难问题, 可通过迭代优化高效求解。

- 稀疏约束原理: L0.5 范数对权重的惩罚呈现“非均匀性”——对 $|w_{ti}| < 0.1$ 的微小权重, 惩罚强度远高于L1范数(如 $|0.05|^{0.5} = 0.22$, $|0.05|^1 = 0.05$), 可快速将冗余特征(权重接近0)的权重压缩至

0；对 $|w_{ti}| > 0.5$ 的重要特征权重，惩罚强度低于 L1 范数（如 $|0.6|^{0.5} = 0.77$ ， $|0.6|^1 = 0.6$ ），能保留关键特征的权重信息。这种特性完美适配时频谱预示中“精准剔除冗余时频特征、保留核心故障特征”的需求，例如在机械故障振动预示中，可精准定位“冲击特征频率对应的输入特征”（权重显著非零）。

3.3.2. 迭代重加权算法实现

由于L0.5范数是非凸、不可微的，直接求解目标函数存在困难，因此采用“迭代重加权最小二乘法(Iterative Reweighted Least Squares, IRLS)” 将非凸问题转化为凸问题近似求解，具体步骤如下：

- 初始化：
 - 初始化模型参数 $W^{(0)}$ （采用 Multitask Wasserstein 模型训练收敛后的权重矩阵作为初始值，加速收敛）、迭代次数 $k=0$ 、最大迭代次数 $K_{\max}=50$ 、收敛阈值 $\epsilon=1e-5$ ；
 - 计算初始权重矩阵的L0.5范数惩罚权重 $w_{ti}^{(0)} = \frac{1}{2\sqrt{|w_{ti}^{(0)}| + \delta}}$ ($\delta=1e-8$ 为避免分母为0的微小常数)。
- 迭代优化：
 - 第 k 次迭代 ($k \geq 1$) :
 - 构建加权损失函数:将 L0.5 范数约束转化为加权 L2 范数约束，目标函数近似为：

$$\min_W \text{Loss}_{\text{Multitask Wasserstein}} + \frac{\gamma}{2} \sum_{t=1}^T \sum_{i=1}^d w_{ti}^{(k-1)} \cdot w_{ti}^2$$

其中 $w_{ti}^{(k-1)}$ 为第 $k-1$ 次迭代的惩罚权重，该函数为凸函数，可通过梯度下降求解。

- **求解加权凸问题：**计算目标函数对 W 的梯度 $\nabla_W \text{Loss}$ ，采用

Adam 优化器（学习率 $\eta=0.001$ ）更新权重矩阵：

$$W^{(k)} = W^{(k-1)} - \eta \cdot \nabla_W \text{Loss}(W^{(k-1)})$$

- **更新惩罚权重：**根据新权重矩阵 $W^{(k)}$ 计算第 k 次迭代的惩罚权重：

$$w_{ti}^{(k)} = \frac{1}{2\sqrt{|w_{ti}^{(k)}|} + \delta}$$

- **收敛判断：**若 $\frac{\|W^{(k)} - W^{(k-1)}\|_F}{\|W^{(k-1)}\|_F} < \epsilon$ 或 $k = K_{\max}$ ，则停止迭代；否则

令 $k=k+1$ ，返回步骤 2.1。

算法优势：迭代重加权算法通过“逐次逼近”将非凸问题转化为一系列凸问题，每次迭代的计算复杂度与 Multitask Wasserstein 模型相当（仅增加权重更新步骤），在普通 GPU 上处理 160 个任务的训练时间 ≤ 12 小时，兼顾精度与效率。

4 多特征预示人工智能预测深度学习算法

4.1MMoE：多门控混合专家模型

MMoE（Multi-gate Mixture of Experts）模型是为解决“任务异

质性导致的特征共享冲突” 而设计的自适应多任务架构，尤其适用于时频谱预示中 “部分频段振动特征相似、部分频段差异显著” 的场景（如机械振动中 100-500Hz 的设备基础振动与 1000-2000Hz 的部件冲击振动预测）。

4.1.1. 模型核心架构

MMoE 在传统 Shared-Bottom 模型（所有任务共享同一底层网络）和 MoE 模型（所有任务共享一组专家网络与单个门控）的基础上，进行了关键改进：

- **专家网络层（Expert Layer）**：构建 K 个结构相同但参数独立的“专家网络”（通常为 3-5 层全连接网络或轻量级 CNN），每个专家负责学习一类特定的特征映射（如专家 1 专注低频振动特征提取、专家 2 专注高频冲击特征提取）。设专家网络的输入为高维时频特征 $X \in \mathbb{R}^{n \times d}$ （ n 为样本数， d 为特征维度），第 k 个专家的输出为 $E_k(X) = \sigma(W_k X + b_k)$ ，其中 $W_k \in \mathbb{R}^{d \times h}$ （ h 为专家输出维度）， σ 为 ReLU 激活函数。

多门控层（Multi-Gate Layer）：为每个预示任务（如 20-50Hz 频段能量预测、500-1000Hz 频段频率偏移预测）单独设计一个门控网络 G_t ，实现 “任务 - 专家” 的动态匹配。门控网络以 X 为输入，输出 K 个专家的权重分配系数：

$$G_t(X) = \text{Softmax}(V_t X + c_t)$$

其中 $V_t \in \mathbb{R}^{d \times K}$ 为门控参数， c_t 为偏置项，输出 $\alpha_{t1}, \alpha_{t2}, \dots, \alpha_{tK}$ 满足 $\sum_{k=1}^K \alpha_{tk} = 1$ ，代表第 t 个任务对第 k 个专家的依赖程度。

任务输出层（Task Output Layer）：第 t 个任务的最终预测结果由专家输出加权求和后，经任务专属头网络得到：

$$y_t = W_t^o \left(\sum_{k=1}^K \alpha_{tk} \cdot E_k(X) \right) + b_t^o$$

其中 $W_t^o \in \mathbb{R}^{h \times 1}$ 为任务头参数，若为分类任务（如故障类型判断），则在输出层添加 **Softmax** 函数。

4.1.2. 关键优势与适配场景

- **解决任务异质性冲突**：通过多门控机制，不同任务可自主选择专家组合 —— 如 “低频振动预测” 任务可能主要依赖专家 1 和专家 2，“高频冲击预测” 任务可能主要依赖专家 3 和专家 4，避免传统 Shared-Bottom 模型中 “共享特征被某类任务主导” 的问题。
- **动态特征选择能力**：门控权重可直观反映任务对专家的依赖关系，例如某故障预示任务对专家 3 的权重 $\alpha_{t3} = 0.8$ ，说明该任务的核心特征由专家 3 提取，为后续特征重要性分析提供可解释性依据。
- **工程适配性**：专家网络可采用轻量化结构（如每层神经元数 ≤ 256 ），在普通 GPU（NVIDIA RTX 3090）上处理 10 万级样本的训练时

间 ≤ 8 小时，满足时频谱预示的实时性需求。

4.1.3. 性能评估设计

针对 MMoE 模型，从 “预测精度” “泛化能力” “可解释性” 三个维度设计评估体系：

- 预测性能指标：

- 回归任务（如频段能量预测）：采用平均绝对误差（MAE）

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_{ti} -$$

$$\hat{y}_{ti}|、均方根误差（RMSE）RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_{ti} - \hat{y}_{ti})^2}$$

- 分类任务（如故障类型判断）：采用准确率（Accuracy）、宏平均 F1 值（Macro-F1）。

- 泛化能力评估：通过 “跨设备迁移测试”（如训练集为设备 A 数据，测试集为设备 B 数据）和 “数据稀疏测试”（训练样本量减少 30%），验证模型在不同场景下的鲁棒性，要求跨设备测试的性能下降幅度 $\leq 15\%$ 。

- 可解释性分析：可视化各任务的门控权重分布，统计 “高权重专家（ $\alpha_{tk} \geq 0.5$ ）” 对应的特征类型，明确不同预示任务的核心特征来源。

4.2 MLP：多层感知机模型

多层感知机（MLP，Multi-Layer Perceptron）是深度学习领域中

最基础的全连接神经网络模型，通过“输入层 - 隐藏层 - 输出层”的层级结构，实现对高维特征的非线性映射，在多特征预示场景（如设备振动状态趋势预测、环境参数关联分析）中，凭借结构简洁、训练成本低、易部署的特点，成为中小规模数据预测任务的优选方案。

4.2.1 模型核心架构

MLP 以全连接为核心设计原则，各层神经元与相邻层神经元完全连接，通过线性变换与非线性激活函数的组合，逐步完成从原始特征到预测结果的映射，具体结构如下：

- 输入层 (Input Layer)：负责接收多特征预示任务的原始输入数据，神经元数量与输入特征维度一致。设输入数据为高维特征向量（如时频谱的统计特征、时域的峰值 / 均值特征等），其数学表达式为 $\mathbf{x} \in \mathbb{R}^d$ ，其中 d 为特征维度（如包含 5 个频段的能量值、3 个时域统计量时， $d=8$ ），输入层不进行特征变换，仅完成数据传递。
- 隐藏层 (Hidden Layers)：由 1 至多个全连接层组成，是 MLP 实现特征抽象的核心模块。每层包含 m 个神经元（根据任务复杂度选择，通常为 64-512 个，多特征预示任务中常用 128-256 个神经元平衡精度与效率），通过线性变换与非线性激活函数提取高阶特征。

设第 l 层 ($l \geq 1$, $l = 1$ 表示第一层隐藏层) 的输入为上一层输

出 $h^{l-1} \in \mathbb{R}^{m_{l-1}}$ ($m_0 = d$ 为输入层维度)，则第 l 层第 i 个神经元的输出为：

$$h_i^l = \sigma(w_i^l \cdot h^{l-1} + b_i^l)$$

其中, $w_i^l \in \mathbb{R}^{m_{l-1}}$ 为第 l 层第 i 个神经元的权重向量, $b_i^l \in \mathbb{R}$ 为偏置项, $\sigma(\cdot)$ 为非线性激活函数。在多特征预示任务中, 常用 ReLU 函数 $\sigma(x) = \max(0, x)$ 解决梯度消失问题, 若处理周期性特征(如振动频率趋势), 可选用 Tanh 函数 增强特征的周期性映射能力。

隐藏层的层数需根据特征复杂度调整: 简单趋势预测(如单一频段能量变化)可设 1-2 层, 复杂多特征关联预测(如多频段耦合振动状态评估)可设 3-4 层, 避免层数过多导致过拟合。

- 输出层 (Output Layer): 根据多特征预示任务类型(回归 / 分类)

设计神经元数量与激活函数, 输出最终预测结果。

设输出层接收最后一层隐藏层的输出 $h^L \in \mathbb{R}^{m_L}$ (L 为隐藏层总层数), 则输出层的数学表达式为:

$$y = \sigma_{out}(W_{out} \cdot h^L + b_{out})$$

其中, $W_{out} \in \mathbb{R}^{k \times m_L}$ (k 为输出维度)、 $b_{out} \in \mathbb{R}^k$ 分别为输出层的权重矩阵与偏置向量, $\sigma_{out}(\cdot)$ 为输出层激活函数:

- 回归任务(如频段能量预测、振动幅值趋势预测): $k=1$, 选用

恒等函数 ($\sigma_{out}(x) = x$), 直接输出连续预测值;

- 分类任务（如设备故障类型判断、振动状态等级划分）： k 为类别数，选用 Softmax 函数（ $\sigma_{\text{out}}(\mathbf{x}_i) = \frac{e^{x_i}}{\sum_{j=1}^k e^{x_j}}$ ），输出各类别的概率分布。

4.2.2 关键优势与适配场景

在多特征预示任务中，MLP 的核心竞争力在于“简洁性与实用性的平衡”，具体优势及适配场景如下：

- **低训练成本与高部署效率：**相比 MMoE 等复杂模型，MLP 无多专家、多门控结构，参数规模更小（如处理 10 维特征、2 层隐藏层的 MLP，参数总量通常 ≤ 10 万）。在普通 CPU（Intel i7-12700K）上，10 万级样本的训练时间 ≤ 2 小时，可部署于边缘设备（如工业控制器、便携式监测终端），满足实时预示需求（如设备现场振动状态实时评估）。
- **强特征适配性：**支持多类型输入特征（时域统计特征、时频谱特征、环境参数等），无需复杂特征预处理（如无需对时频谱进行卷积特征提取），仅需标准化（如 Z-Score 归一化）即可输入模型，适用于“特征类型多样但数据量有限”的场景（如中小型工厂的设备监测数据，样本量通常 ≤ 5 万）。
- **易调优与可解释性：**模型结构简单，超参数（隐藏层层数、神经元数量、学习率）调整成本低，可通过 权重可视化 分析核心特征：

例如，若输出层某权重绝对值较大，说明对应输入特征（如 500-1000Hz 频段能量）对预测结果影响显著，为多特征预示任务的“关键特征筛选”提供依据。

5 多特征预示人工智能预测性能评估方法

多特征预示人工智能预测的核心目标是在复杂特征交互场景下（如 13 个以上输入特征对应 160 个同源输出特征），实现精准、稳定且可解释的预测。性能评估需覆盖预测精度、泛化能力、计算效率、特征有效性四大维度，同时结合多任务、多特征的特殊性，建立分层评估体系，确保算法在工程场景中兼具科学性与实用性。

5.1 评估体系设计原则

在设计评估方法前，需遵循以下核心原则，确保评估结果能真实反映算法在多特征预示场景中的表现：

1. 多维度覆盖：避免单一依赖“预测误差”指标，需同时评估模型对噪声的鲁棒性、特征冗余的容忍度、多任务间的协同效果；
2. 工程适配性：评估指标需贴合实际应用场景（如振动预测需关注“高频段误差”“动态响应延迟”），而非仅追求理论性能；

3. 可解释性辅助：在定量指标外，需通过特征重要性、任务相关性等定性分析，验证模型决策逻辑的合理性；
4. 对比基准明确：需引入经典算法（如普通线性回归、单任务随机森林）作为基准，突出多特征、多任务算法的优势。

5.2 核心评估指标与计算方法

根据多特征预示的任务特性（回归为主，如振动幅值、频段能量预测），从预测精度、泛化能力、计算效率三个核心维度设计指标，具体如下：

5.2.1 预测精度指标（定量衡量误差大小）

针对 160 个同源输出特征的回归任务，采用多指标组合评估，避免单一指标掩盖局部误差问题：

指标名称	计算公式	含义与适用场景
平均绝对误差 (MAE)	$MAE = \frac{1}{n} \sum_{i=1}^n y_i - \hat{y}_i $	
均方根误差 (RMSE)	$RMSE = \sqrt{\frac{1}{n \times T} \sum_{t=1}^T \sum_{i=1}^n (y_{t,i} - \hat{y}_{t,i})^2}$	放大较大误差的影响，适用于“对极端偏差敏感”的场景（如故障振动峰值预测，需严格控制大误差）。
平均绝对百分比误差 (MAPE)	$MAPE = \frac{100\%}{n} \sum_{i=1}^n \left \frac{y_i - \hat{y}_i}{y_i} \right $	

频段加权误差 (BWE)	$BWE = \frac{1}{K} \sum_{k=1}^K w_k \cdot MAE_k$	
-----------------	--	--

5.2.2 泛化能力指标（衡量模型稳定性与适应性）

多特征预示需应对“特征维度变化”“数据分布偏移”“噪声干扰”等工程场景，需通过以下指标评估泛化能力：

指标名称	测试方法与计算	核心意义
跨数据集迁移误差 (TRE)	1. 训练集：设备 A 的振动数据（含 13 个输入特征）；2. 测试集：设备 B 的同类振动数据（输入特征一致，数据分布略有差异）；3. 计算： $TRE = \frac{RMSE_{\text{测试集}} - RMSE_{\text{训练集}}}{RMSE_{\text{训练集}}} \times 100\%$	评估模型在“相似设备、不同数据分布”场景下的适配性，优秀模型的 TRE 应≤15%（性能下降幅度可控）。
特征维度鲁棒性 (FDR)	1. 原始输入维度 d=13，分别随机删减 20%（d=10）、40%（d=8）的非核心特征；2. 计算不同维度下的 RMSE 变化率： $FDR = \frac{RMSE_d - RMSE_{13}}{RMSE_{13}} \times 100\%$	验证模型对“特征缺失”的容忍度，多特征预示模型需满足：d=10 时 $FDR \leq 8\%$ ，d=8 时 $FDR \leq 15\%$ 。
噪声鲁棒性 (NR)	1. 在输入特征中添加不同信噪比（SNR）的高斯噪声（如 SNR=20dB、10dB、5dB）；2. 计算噪声下的 RMSE 与无噪声 RMSE 的比值： $NR = \frac{RMSE_{SNR}}{RMSE_{clean}}$	评估模型抗干扰能力，工业场景中需满足：SNR = 10dB 时 NR≤1.2（误差增幅≤20%）。
多任务协同误差 (MCE)	1. 计算 160 个输出任务的 RMSE 标准差： $\sigma_{RMSE} = \sqrt{\frac{1}{T} \sum_{t=1}^T (RMSE_t - \overline{RMSE})^2}$ ；2. 定义 $MCE = \frac{\sigma_{RMSE}}{\overline{RMSE}} \times 100\%$ ；2. ($\overline{RMSE}$ 为所有任务的平均 RMSE)	衡量多任务间的性能均衡性， $MCE \leq 10\%$ 说明模型对 160 个输出特征的预测精度稳定，无“部分任务优、部分任务差”的失衡问题。

5.2.3 计算效率指标（适配大数据与实时场景）

根据项目需求(支持 GPU / 多核并行、单一特征数据 >1GB)，
需评估模型在大规模数据下的效率：

指标名称	测试环境与计算	工程要求
训练耗时 (TT)	环境：GPU (NVIDIA RTX 4090) / CPU (4 核 Intel i7-13700K)；数据量：输入特征数据量 10GB (含 100 万样本)；计算：记录模型从数据加载到训练收敛的总时间 (单位：分钟)	GPU 训练耗时≤60 分钟，CPU 多核并行耗时≤180 分钟，满足工程快速迭代需求。
预测延迟 (PD)	输入：单条多特征样本 (13 个输入特征，数据量 1KB)；计算：模型从接收输入到输出 160 个预测结果的平均时间 (单位：毫秒)	实时预测场景 (如设备振动实时监测) 需满足 PD≤50ms，非实时场景需 PD≤200ms。
内存占用 (MO)	测试：模型训练时的最大 GPU/CPU 内存占用 (单位：GB)；计算： $MO = \frac{\text{最大内存占用}}{\text{硬件内存总量}} \times 100\%$	GPU 内存占用≤60% (如 24GB GPU 需 ≤14.4GB)，CPU 内存占用≤40%，避免内存溢出。

5.3 特征有效性与模型可解释性评估

多特征预示的核心是 “利用关键特征提升预测精度”，需通过定性 + 定量方法验证特征有效性，同时增强模型可解释性：

5.3.1 特征重要性评估

针对不同算法类型，采用适配的特征重要性计算方法，识别对 160 个输出特征起关键作用的输入特征：

1. 树模型（决策树、随机森林、极端树）：

基于“节点分裂贡献度”：统计每个输入特征在所有树中作为分裂特征的总次数，或其降低的不纯度（如 MSE）总和，按占比排序得到重要性排名；

案例：若“时频熵特征”的重要性占比达 25%，说明其对振动预测的贡献显著高于其他输入特征。

2. 线性模型（GroupLasso）：

基于“权重绝对值”：计算输入特征在 160 个任务中权重的平均绝对值， $\text{Importance}(j) = \frac{1}{T} \sum_{t=1}^T |w_{j,t}|$ （ $w_{j,t}$ 为第 j 个输入特征在第 t 个任务的权重），值越大说明特征越重要。

3. 深度学习模型（MMoE、MLP）：

基于“注意力权重 / 梯度贡献”：MMoE 模型通过门控权重分析任务对专家的依赖，进而关联输入特征（如专家 1 专注低频特征，若某任务对专家 1 的权重高，则低频输入特征重要）；

MLP 模型通过计算输入特征对输出的梯度绝对值之和，衡量特征影响度。

5.3.2 模型可解释性分析

1. 决策路径可视化：

对树模型，输出关键样本的决策路径（如“当输入特征 $A > 5$ 且特征 $B < 3$ 时，预测频段 C 的振动幅值为 $1.2g$ ”），验证决策逻辑是否符合工程常识（如振动频率与幅值的物理关联）；

2. 任务相关性热力图：

对多任务算法（GroupLasso、Multitask Wasserstein），计算 160 个输出任务的预测误差相关性矩阵，通过热力图展示“高相关性任务簇”（如频段 20-100Hz 的输出特征误差高度相关），验证任务分组的合理性；

3. 误差归因分析：

对预测误差较大的样本，分析其输入特征的异常程度（如某样本的“冲击特征值”偏离均值 3 倍），判断误差是由“特征噪声”还是“模型未学习到关键模式”导致，为模型优化提供方向。